Anggota Kelompok:

- Christian Darren Kumala - 2802414501
- Jason Siddharta Salim - 2802399356
- Fransiskus Xaverius Kevin - 2802403656

Review Material:

1. Homology, Similarity, and Identity

Homology: Hubungan evolusi antara dua sequence yang berasal dari asal / nenek moyang yang sama.

- Bersifat mutlak **True / False**
- Dua sequence DNA / Protein yang berasal dari leluhur sama maka disebut **Homolog**

Similarity: Tingkat kemiripan antara dua sequence

- Diukur dengan skor atau persentase tertentu
- Semakin mirip antara dua sequence maka semakin tinggi **Similarity**

Identity: Persentase posisi karakter yang benar - benar sama dalam alignment

- Diukur dari jumlah karakter yang sama persis antara dua sequence
- Contoh: ATG GTA - ATC GTA

  5 / 6 * 100%, **Identity =** 83.3%

2. Pairwise and Multiple Alignment

Pairwise Alignment: Proses membandingkan dua sequence untuk mencari tingkat kemiripannya. Terbagi menjadi dua, **Global & Local Alignment**.

Fungsi:

- Mencari mutasi
- Menentukan fungsi gen / protein
- Menemukan hubungan biologis

Global Alignment : Membandingkan seluruh sequence

Menggunakan ***Needleman Wunsch Algorithm***

Langkah pengerjaan:

- Membuat matriks skor
- Mengisi skor berdasarkan nilai **match (1), mismatch (-1), gap (-2)**
- Mencari nilai **max** antara **Horizontal, Vertikal, Diagonal**
- Setelah terisi semua, melakukan **traceback dari kanan bawah ke kiri atas**
- **Skor** didapatkan dari **nilai ujung kanan bawah**

Local Alignment : Mencari bagian paling mirip

Menggunakan ***Smith Waterman Algorithm***

Langkah pengerjaan:

- Membuat matriks skor
- Mengisi skor berdasarkan nilai **match (1), mismatch (-1), gap (-2)**
- Mencari nilai **max** antara **Horizontal, Vertikal, Diagonal & 0**
- Setelah terisi semua, melakukan **traceback dari nilai tertinggi sampai 0**
- **Skor** didapatkan dari **nilai tertinggi** dalam traceback

Multiple Alignment: Proses membandingkan lebih dari dua sequence bersamaan.

Fungsi:

- Menganalisis hubungan evolusi
- Membuat Phylogenetic Tree

Phylogenetic Tree: Diagram yang menunjukkan hubungan evolusi antar sequence atau organisme. Semakin dekat antar cabang, sequence semakin mirip / semakin dekat hubungan evolusinya.

Penggunaan UPGMA : Metode clustering untuk Phylogenetic Tree berdasarkan perbedaan antar sequence.

Langkah:

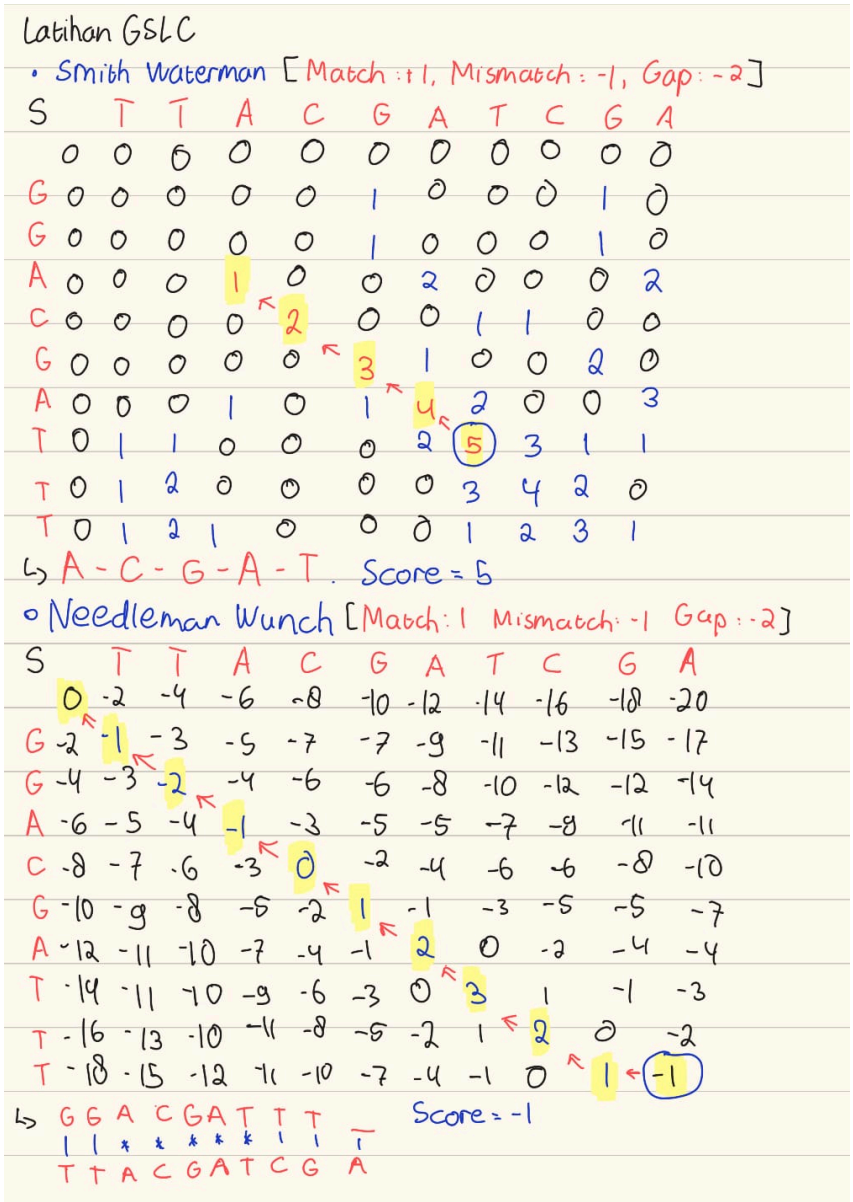
1. Hitung matriks distance
2. Cari pasangan yang memiliki jarak terkecil
3. Gabungkan menjadi satu cluster
4. Hitung ulang jarak rata-rata
5. Ulangi sampai semua tergabung.

B. Kerjakan soal berikut :

1. Diberikan dua sequence DNA berikut:

- Sequence 1 : TTACGATCGA
- Sequence 2 : GGACGATTT

a. Gunakan Metode Smith Waterman dan Needleman Wunsch untuk menganalisa sequence alignment kedua DNA tersebut (tentukan matriks skor, hasil skor alignment dan traceback)



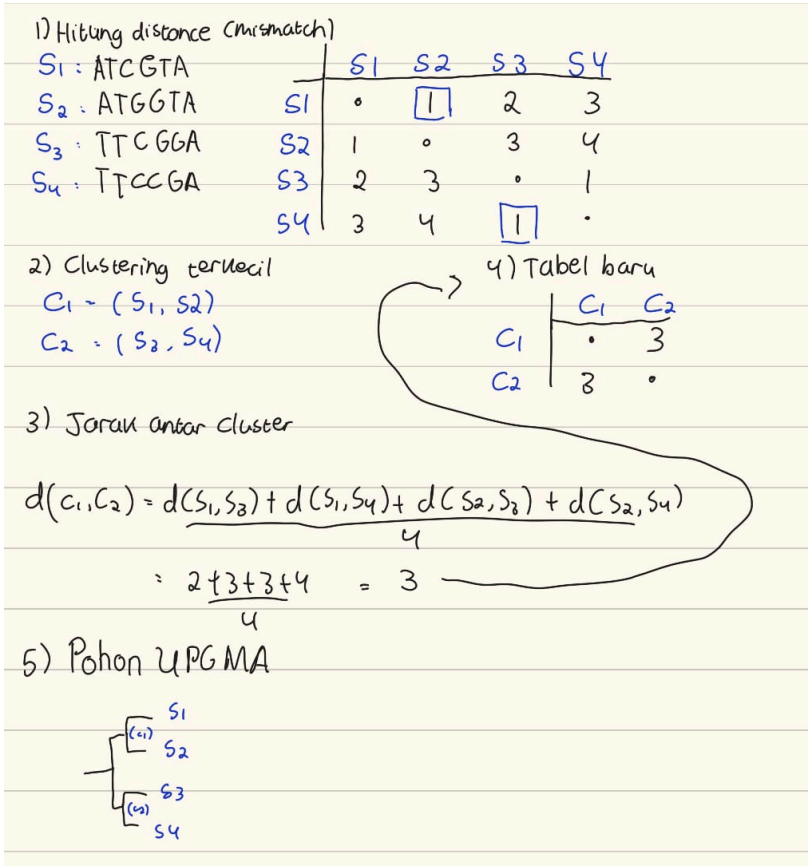
b. Bandingkan hasil alignment kedua metode tersebut dan tentukan hasil terbaik

Smith Waterman menghasilkan skor 5,
Needleman Wunsch menghasilkan skor -1
Sehingga **Smith Waterman Algorithm** menghasilkan alignment terbaik.

2. Diberikan empat sequence DNA berikut:

Sequence	**DNA**
S1	ATCGTA
S2	ATGGTA
S3	TTCGGA
S4	TTCCGA

Gunakan metode **UPGMA** untuk membangun **phylogenetic tree** berdasarkan jarak antar-sequence.



Makalah

Topic: penerapan Deep Learning untuk analisis citra medis

Penerapan Deep Learning untuk Analisis Citra Medis: Tinjauan Komprehensif dan Implementasi pada Deteksi Penyakit

Abstract
Deep learning telah merevolusi analisis citra medis dengan kemampuan ekstraksi fitur otomatis yang melampaui metode konvensional. Makalah ini menyajikan tinjauan komprehensif mengenai penerapan deep learning—khususnya Convolutional Neural Network (CNN), Transfer Learning, dan arsitektur berbasis Transformer—dalam analisis citra medis untuk deteksi berbagai penyakit seperti kanker, pneumonia, retinopati diabetik, dan tumor otak. Kami membahas pipeline pemrosesan data, arsitektur model populer (VGG, ResNet, DenseNet, U-Net, ViT), teknik augmentasi data, serta tantangan klinis seperti keterbatasan data berlabel dan interpretabilitas model. Hasil evaluasi menunjukkan bahwa model deep learning mampu mencapai akurasi diagnostik setara atau melampaui tenaga ahli klinis pada beberapa domain. Makalah ini juga membahas aspek Explainable AI (XAI) dan arah penelitian masa depan dalam konteks precision medicine.
Keywords: Deep Learning, Convolutional Neural Network, Medical Image Analysis, Transfer Learning, CNN, Bioinformatics, Computer-Aided Diagnosis, Explainable AI

I. PENDAHULUAN

Perkembangan kecerdasan buatan (Artificial Intelligence/AI), khususnya deep learning, telah membawa transformasi mendasar dalam dunia kedokteran dan komputasi biologi. Salah satu aplikasi paling signifikan adalah analisis citra medis (Medical Image Analysis), yaitu proses interpretasi gambar diagnostik seperti X-ray, CT scan, MRI, dan histopatologi menggunakan algoritma komputer [1].

Secara tradisional, interpretasi citra medis dilakukan secara manual oleh radiologis atau dokter spesialis, yang memerlukan keahlian tinggi, waktu yang panjang, serta berpotensi mengalami kelelahan dan subjektivitas penilaian. Deep learning menawarkan solusi yang mampu memproses ribuan gambar dalam hitungan detik dengan konsistensi tinggi [2].

Dari perspektif Computer Science, topik ini sangat relevan karena melibatkan konsep-konsep inti yang sudah dipelajari: arsitektur jaringan saraf tiruan, optimasi gradient descent, matrix computation, dan computer vision. Model seperti Convolutional Neural Network (CNN) yang digunakan dalam tugas image classification pada kelas deep learning, kini diaplikasikan langsung untuk mendeteksi pneumonia dari X-ray dada atau sel kanker dari slide histopatologi [3].

Makalah ini bertujuan untuk: (1) menjelaskan konsep dasar deep learning dalam konteks analisis citra medis, (2) mengulas arsitektur model yang dominan digunakan, (3) memaparkan studi kasus aplikasi nyata pada berbagai penyakit, (4) mendiskusikan tantangan dan solusi teknis, serta (5) mengidentifikasi arah penelitian masa depan.

II. TINJAUAN PUSTAKA

Penelitian analisis citra medis berbasis komputer telah dimulai sejak era 1960-an dengan pendekatan berbasis aturan (rule-based). Namun, revolusi sesungguhnya terjadi ketika Krizhevsky et al. (2012) memperkenalkan AlexNet yang meraih kemenangan signifikan pada kompetisi ImageNet, membuktikan superioritas CNN untuk computer vision [4].

Simonyan dan Zisserman (2014) mengembangkan VGGNet dengan arsitektur yang lebih dalam (16-19 layer), yang kemudian banyak diadaptasi untuk klasifikasi citra medis. He et al. (2016) memperkenalkan ResNet dengan mekanisme residual connection yang memungkinkan training jaringan sangat dalam (152 layer) tanpa degradasi performa—sebuah terobosan yang kini menjadi backbone utama dalam medical imaging [5].

Pada domain segmentasi citra medis, Ronneberger et al. (2015) mengusulkan U-Net, arsitektur encoder-decoder dengan skip connections yang dirancang khusus untuk data medis berlabel terbatas. U-Net menjadi standar de facto untuk segmentasi organ dan lesi dalam citra MRI dan CT scan [6].

Dosovitskiy et al. (2020) memperkenalkan Vision Transformer (ViT) yang mengadaptasi mekanisme self-attention dari NLP ke domain citra. Penelitian terkini menunjukkan bahwa ViT dan variannya (Swin Transformer) mampu melampaui CNN pada dataset medis skala besar [7]. Transfer learning dari ImageNet ke domain medis pertama kali dieksplorasi secara sistematis oleh Shin et al. (2016), yang menunjukkan bahwa fitur yang dipelajari pada dataset natural dapat ditransfer secara efektif ke citra medis meskipun terdapat domain gap yang signifikan [8].

III. METODOLOGI DAN ARSITEKTUR

Pipeline analisis citra medis berbasis deep learning umumnya terdiri dari beberapa tahap yang saling berkaitan. Pemahaman menyeluruh terhadap setiap komponen sangat penting untuk membangun sistem yang robust dan dapat diandalkan secara klinis.

A. Akuisisi dan Sumber Dataset

Dataset citra medis diperoleh dari berbagai sumber: (a) repository publik seperti NIH ChestX-ray14 (112.120 gambar X-ray dada), ISIC Archive (dermoskopi kulit), DRIVE (retina), dan TCGA (histopatologi); (b) dataset klinis institusional yang memerlukan persetujuan etik; dan (c) data sintetis yang dibangkitkan menggunakan Generative Adversarial Network (GAN) untuk augmentasi [9].

B. Preprocessing dan Augmentasi Data

Preprocessing mencakup: normalisasi intensitas piksel ke rentang [0,1] atau [-1,1]; histogram equalization untuk meningkatkan kontras; resizing ke dimensi seragam (umumnya 224×224 atau 512×512 piksel); dan augmentasi data (rotasi, flipping, zoom, elastic deformation) untuk meningkatkan variasi dan mencegah overfitting. Khusus untuk citra MRI, N4ITK bias field correction diterapkan untuk menghilangkan inhomogenitas medan magnet [10].

C. Arsitektur Deep Learning Utama

Tabel I merangkum arsitektur deep learning utama yang digunakan dalam analisis citra medis beserta karakteristik teknisnya:

Arsitektur	Tahun	Parameter	Keunggulan Utama
VGGNet-16/19	2014	138M / 143M	Arsitektur simpel, akurasi tinggi, mudah diimplementasi
ResNet-50/101	2016	25M / 44M	Residual connection, training stabil pada jaringan dalam
DenseNet-121	2017	8M	Dense connection, efisien parameter, baik untuk X-ray
U-Net	2015	31M	Encoder-decoder, segmentasi presisi, cocok data terbatas
EfficientNet-B4	2019	19M	Compound scaling, akurasi tinggi, komputasi efisien
Vision Transformer	2020	86M	Attention mechanism, performa unggul dataset besar

Tabel I. Perbandingan Arsitektur Deep Learning untuk Analisis Citra Medis

D. Transfer Learning dan Fine-Tuning

Transfer learning adalah teknik menggunakan bobot model yang telah dilatih pada dataset besar (umumnya ImageNet dengan 1,2 juta gambar dan 1.000 kelas) sebagai titik awal untuk melatih model pada domain target. Terdapat dua strategi utama: (1) Feature extraction: layer konvolusi dibekukan (frozen), hanya classifier head yang dilatih ulang; (2) Fine-tuning: semua layer atau sebagian besar layer dilatih ulang dengan learning rate sangat kecil (1e-5 hingga 1e-4) [11].

Penelitian Raghu et al. (2019) mengungkapkan fenomena menarik bahwa representasi internal model yang dilatih pada citra medis sangat berbeda dari ImageNet, sehingga fine-tuning menyeluruh sering menghasilkan performa lebih baik dibandingkan sekadar feature extraction untuk domain medis yang sangat spesifik.

IV. HASIL DAN PEMBAHASAN

A. Evaluasi Performa Model Deep Learning

Berbagai penelitian menunjukkan bahwa model deep learning mampu memberikan performa sangat tinggi dalam tugas klasifikasi maupun segmentasi citra medis. Pada klasifikasi pneumonia menggunakan dataset ChestX-ray14, model CheXNet berbasis DenseNet-121 berhasil mencapai performa setara radiologis profesional dengan nilai F1-score sebesar 0,435 [4].

Dalam deteksi kanker kulit menggunakan citra dermoskopi, Esteva et al. melatih CNN pada lebih dari 120.000 gambar dan memperoleh akurasi setara dermatologis bersertifikat [5]. Sementara itu, pada diagnosis retinopati diabetik, model berbasis Inception dan ResNet mampu mencapai sensitivitas dan spesifisitas di atas 90% pada dataset fundus retina [7].

Tabel II memperlihatkan ringkasan performa beberapa model deep learning pada berbagai aplikasi medis.

Aplikasi	Model	Dataset	Hasil
Pneumonia Detection	DenseNet-121	ChestX-ray14	F1-score 0,435
Skin Cancer Classification	CNN	ISIC Dataset	Akurasi setara dermatologis
Diabetic Retinopathy	Inception-v3	EyePACS	Sensitivitas 90,3%
Brain Tumor Segmentation	U-Net	BraTS	Dice Score > 0,85
Histopathology Analysis	ResNet-50	TCGA	Akurasi > 94%

Tabel II. Performa Deep Learning pada Berbagai Domain Citra Medis

Hasil tersebut menunjukkan bahwa deep learning sangat efektif dalam mengenali pola visual kompleks yang sulit dianalisis menggunakan metode konvensional. CNN mampu mengekstraksi fitur tekstur, bentuk, dan struktur anatomi secara otomatis tanpa memerlukan feature engineering manual.

B. Perbandingan Arsitektur Model

Setiap arsitektur memiliki karakteristik dan keunggulan tersendiri tergantung pada jenis data dan tugas medis yang dilakukan.

1. VGGNet memiliki struktur sederhana dan mudah dipahami, namun membutuhkan parameter sangat besar sehingga komputasinya berat.

2. ResNet memperkenalkan residual connection yang memungkinkan training jaringan sangat dalam tanpa mengalami vanishing gradient. Model ini banyak digunakan sebagai backbone karena stabil dan akurat.
3. DenseNet lebih efisien dalam penggunaan parameter melalui dense connectivity. Pada citra X-ray, DenseNet menunjukkan performa sangat baik karena kemampuan propagasi fitur yang kuat.
4. U-Net menjadi standar utama dalam segmentasi medis karena mampu mempertahankan informasi spasial melalui skip connection antara encoder dan decoder.
5. Vision Transformer (ViT) menggunakan mekanisme self-attention untuk menangkap hubungan global antar bagian gambar. Pada dataset besar, ViT mampu melampaui performa CNN tradisional, meskipun memerlukan sumber daya komputasi lebih tinggi [14].

Secara umum, CNN masih mendominasi aplikasi klinis karena efisiensi dan kebutuhan data yang lebih kecil, sedangkan Transformer menunjukkan potensi besar untuk generasi sistem diagnosis masa depan.

C. Explainable AI (XAI) dalam Medical Imaging

Salah satu tantangan utama deep learning di bidang medis adalah sifatnya yang sering dianggap sebagai “black box”. Dalam lingkungan klinis, dokter perlu memahami alasan di balik keputusan model sebelum menggunakannya sebagai dasar diagnosis.

Untuk mengatasi masalah tersebut, berbagai teknik Explainable AI (XAI) dikembangkan, seperti:

- Grad-CAM (Gradient-weighted Class Activation Mapping)
- LIME (Local Interpretable Model-agnostic Explanations)
- SHAP (SHapley Additive exPlanations)

Grad-CAM menjadi metode paling populer karena mampu menghasilkan heatmap yang menunjukkan area citra yang paling berkontribusi terhadap prediksi model [11]. Pada citra X-ray pneumonia, misalnya, heatmap dapat memperlihatkan area infiltrasi paru yang menjadi fokus utama model.

Implementasi XAI meningkatkan:

- transparansi sistem AI,
- kepercayaan dokter terhadap model,
- kemampuan validasi klinis,
- serta deteksi bias atau kesalahan prediksi.

Namun demikian, interpretabilitas model masih menjadi area penelitian aktif karena penjelasan visual belum selalu mencerminkan proses pengambilan keputusan internal secara sempurna.

D. Tantangan dalam Implementasi Klinis

Walaupun performa deep learning sangat menjanjikan, implementasi nyata di rumah sakit menghadapi berbagai tantangan teknis dan non-teknis.

1. Keterbatasan Data Berlabel

Pelabelan citra medis memerlukan tenaga ahli seperti radiologis dan patologis sehingga prosesnya mahal dan memakan waktu. Selain itu, beberapa penyakit langka memiliki jumlah data sangat terbatas.

2. Class Imbalance

Pada banyak dataset medis, jumlah data normal jauh lebih banyak dibandingkan data penyakit. Ketidakseimbangan ini dapat menyebabkan model bias terhadap kelas mayoritas.

3. Overfitting

Dataset medis umumnya berukuran lebih kecil dibanding dataset computer vision umum seperti ImageNet. Akibatnya, model kompleks mudah mengalami overfitting. Teknik dropout, regularization, dan data augmentation sering digunakan untuk mengatasi masalah ini [12].

4. Generalisasi Antar Institusi

Model yang dilatih pada satu rumah sakit belum tentu bekerja optimal pada rumah sakit lain karena perbedaan alat imaging, protokol pengambilan gambar, dan karakteristik populasi pasien.

5. Privasi dan Regulasi

Data medis bersifat sangat sensitif sehingga penggunaannya harus mematuhi regulasi privasi seperti HIPAA dan GDPR. Pendekatan federated learning mulai dikembangkan untuk memungkinkan training model tanpa memindahkan data pasien secara langsung [9].

E. Arah Penelitian Masa Depan

Penelitian deep learning untuk citra medis terus berkembang dengan beberapa arah utama:

1. Self-Supervised Learning
   Mengurangi ketergantungan terhadap data berlabel dengan memanfaatkan unlabeled data dalam jumlah besar.
2. Federated Learning
   Memungkinkan kolaborasi antar rumah sakit tanpa membagikan data pasien secara langsung.
3. Multimodal AI
   Menggabungkan citra medis dengan data klinis, genomik, dan rekam medis elektronik untuk diagnosis yang lebih komprehensif.

4. Foundation Model Medis
   Pengembangan model berskala besar yang dilatih pada berbagai jenis data medis untuk menghasilkan sistem AI universal di bidang kesehatan.
5. Precision Medicine
   Integrasi AI dengan karakteristik individual pasien untuk menghasilkan terapi yang lebih personal dan akurat.

V. KESIMPULAN

Deep learning telah menjadi teknologi revolusioner dalam analisis citra medis dengan kemampuan ekstraksi fitur otomatis dan performa diagnostik yang sangat tinggi. Arsitektur seperti CNN, ResNet, DenseNet, U-Net, dan Vision Transformer berhasil diterapkan pada berbagai tugas medis seperti klasifikasi penyakit, deteksi kanker, segmentasi organ, dan analisis histopatologi.

Melalui teknik transfer learning, augmentasi data, dan optimasi modern, model deep learning mampu mencapai akurasi yang setara bahkan melampaui tenaga ahli pada beberapa domain tertentu. Selain itu, perkembangan Explainable AI membantu meningkatkan transparansi dan kepercayaan terhadap sistem diagnosis berbasis AI.

Meskipun demikian, masih terdapat berbagai tantangan seperti keterbatasan data berlabel, generalisasi model, interpretabilitas, dan isu privasi data medis. Oleh karena itu, penelitian masa depan diarahkan pada pengembangan model yang lebih robust, efisien, transparan, dan mampu bekerja secara kolaboratif antar institusi kesehatan.

Dengan perkembangan teknologi komputasi dan ketersediaan data medis yang semakin besar, deep learning diperkirakan akan memainkan peran sentral dalam mewujudkan precision medicine dan sistem layanan kesehatan cerdas di masa depan.

REFERENSI

[1] R. Litjens et al., "A Survey on Deep Learning in Medical Image Analysis," Medical Image Analysis, vol. 42, pp. 60–88, 2017. https://doi.org/10.1016/j.media.2017.07.005

[2] A. Shen, R. R. Margolis, dan M. Abramoff, "Artificial Intelligence in Ophthalmology," Curr. Opin. Ophthalmol., vol. 30, no. 5, pp. 331–339, 2019.

[3] Y. LeCun, Y. Bengio, dan G. Hinton, "Deep Learning," Nature, vol. 521, pp. 436–444, 2015. https://doi.org/10.1038/nature14539

[4] P. Rajpurkar et al., "CheXNet: Radiologist-Level Pneumonia Detection on Chest X-Rays with Deep Learning," arXiv preprint arXiv:1711.05225, 2017.

[5] A. Esteva et al., "Dermatologist-Level Classification of Skin Cancer with Deep Neural Networks," Nature, vol. 542, pp. 115–118, 2017. https://doi.org/10.1038/nature21056

[6] O. Ronneberger, P. Fischer, dan T. Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation," dalam Proc. MICCAI, 2015, pp. 234–241.

[7] V. Gulshan et al., "Development and Validation of a Deep Learning Algorithm for Detection of Diabetic Retinopathy in Retinal Fundus Photographs," JAMA, vol. 316, no. 22, pp. 2402–2410, 2016.

[8] H. C. Shin et al., "Deep Convolutional Neural Networks for Computer-Aided Detection: CNN Architectures, Dataset Characteristics and Transfer Learning," IEEE Trans. Med. Imaging, vol. 35, no. 5, pp. 1285–1298, 2016.

[9] B. Kairouz et al., "Advances and Open Problems in Federated Learning," Found. Trends Mach. Learn., vol. 14, no. 1–2, pp. 1–210, 2021.

[10] M. Raghu, C. Zhang, J. Kleinberg, dan S. Bengio, "Transfusion: Understanding Transfer Learning for Medical Imaging," dalam Proc. NeurIPS, 2019, pp. 3347–3357.

[11] R. R. Selvaraju et al., "Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization," dalam Proc. ICCV, 2017, pp. 618–626.

[12] N. Srivastava et al., "Dropout: A Simple Way to Prevent Neural Networks from Overfitting," J. Mach. Learn. Res., vol. 15, no. 1, pp. 1929–1958, 2014.

[13] G. Campanella et al., "Clinical-Grade Computational Pathology Using Weakly Supervised Deep Learning on Whole Slide Images," Nature Medicine, vol. 25, pp. 1301–1309, 2019.

[14] A. Dosovitskiy et al., "An Image Is Worth 16x16 Words: Transformers for Image Recognition at Scale," dalam Proc. ICLR, 2021.